

Compléments sur l'ACP

(1)

I] Décomposition en valeurs singulières:

théorème: A matrice $n \times p$ à valeurs réelles.

• $r = \text{rang}(A) \leq \min(n, p)$.

• $U = \left(u_1 \mid u_2 \mid \dots \mid u_r \right) \uparrow$ matrice de taille $n \times r$ constituée d'une B.O.N (Base orthonormée) de vecteurs propres de $X \cdot X^T$ (matrice $n \times n$ symétrique positive de rang r) associés aux r valeurs propres > 0 rangées dans l'ordre décroissant ($\lambda_1 \geq \lambda_2 \dots \geq \lambda_r > 0$)

• $V = \left(v_1 \mid \dots \mid v_r \right) \uparrow$ matrice $p \times r$,

constituée d'une BON de vecteurs propres de $X^T \cdot X$ ($p \times p$) associées à $\lambda_1 \geq \lambda_2 \dots \geq \lambda_r > 0$ (mêmes valeurs propres pour XX^T et X^TX)

• $D = \begin{pmatrix} \sigma_1(A) & & 0 \\ & \ddots & \\ 0 & & \sigma_r(A) \end{pmatrix}$ où $\sigma_i(A) = \sqrt{\lambda_i}$

• Alors $A = U \cdot D \cdot V^T$
$$= \sum_{i=1}^r \sigma_i(A) u_i \cdot v_i^T$$

II

THEOREME d'APPROXIMATION MATRICIELLE:

(2)

Pour une matrice A $n \times p$ de colonnes a_1, \dots, a_p
On note $\|A\|_F^2 = \sum_{j=1}^p \|a_j\|^2 = \sum_{i,j=1}^p A_{i,j}^2 = \text{Tr}(A \cdot A^T)$

$\|\cdot\|_F$ est appelée norme de Frobenius de la matrice A .
(et il s'agit bien d'une norme). Ainsi, pour
2 matrices A et B de même taille

$$\|A - B\|_F^2 = \sum_{j=1}^p \|a_j - b_j\|^2$$

où a_j et b_j désignent les colonnes de A et B .

Remarque : Si \tilde{a}_i et \tilde{b}_i , $i=1, \dots, n$, correspondent
aux lignes de A et B , on a aussi

$$\|A - B\|_F^2 = \sum_{i=1}^n \|\tilde{a}_i - \tilde{b}_i\|^2$$

THEOREME: A matrice $n \times p$ de rang r , $d < r$.

$$\mathcal{L}_d = \{ Z \text{ de taille } n \times p, \text{rg}(Z) \leq d \}.$$

Alors

$$\inf_{Z \in \mathcal{L}_d} \|A - Z\|_F^2 = \sum_{k=d+1}^r \tau_k^2(A)$$

De plus, l'inf est atteint ~~de~~ en :

$$A_d = \sum_{k=1}^d \tau_k(A) \cdot u_k \cdot v_k^T$$

PREUVE: Voir Giraud Théorème C.5.

III APPLICATION à l'ACP:

(3)

X matrice des observations de taille $n \times p$.

On note $X^{(1)}, \dots, X^{(n)}$ ses lignes.

S_d : sous-espace vectoriel de dimension $\leq d$ de \mathbb{R}^p .

$P_{S_d}(X) = \begin{pmatrix} \frac{P_{S_d}(X^{(1)})}{P_{S_d}(X^{(n)})} \end{pmatrix}$ matrice des projections

orthogonales des lignes de X

$P_{S_d}(X)$ est de rang $\leq d$ donc appartient à \mathcal{L}_d .

Comme de plus, on a

$$\sum_{i=1}^n \|X^{(i)} - P_{S_d}(X^{(i)})\|^2 = \|X - P_{S_d}(X)\|_F^2$$

on déduit du théorème précédent le corollaire suivant:

COROLLAIRE:

$\inf_{\substack{\text{ser } S_d \\ \text{de dim} \leq d}} \sum_{i=1}^n \|X^{(i)} - P_{S_d}(X^{(i)})\|^2$ est atteint

en
$$X_d = \sum_{k=1}^d \tau_k(X) \cdot u_k \cdot v_k^T$$

PREUVE du COROLLAIRE:

(4)

D'après le théorème, on a clairement :

$$\inf_{\substack{\text{ser } S_d \\ \dim S_d \leq d}} \sum_{i=1}^n \|X^{(i)} - P_{S_d}(X^{(i)})\|^2 \geq \inf_{Z \in \mathcal{Z}_d} \|X - Z\|_F^2$$

$$\text{Or, } X_d \stackrel{(*)}{=} \begin{pmatrix} P_{S_d^*}(X^{(1)}) \\ \vdots \\ P_{S_d^*}(X^{(n)}) \end{pmatrix} = P_{S_d^*}(X)$$

où $S_d^* = \text{Vect} \{v_1, \dots, v_d\}$ d'où le résultat.

(*) : Prouvons cette égalité. Par construction,

$$X^{(i)} = \sum_{j=1}^n c_j(i) \cdot v_j$$

et

$$X_d^{(i)} = \sum_{j=1}^d c_j(i) \cdot v_j \quad \text{où} \quad \boxed{c_j(i) := \langle v_j, X^{(i)} \rangle = \langle v_j, X \rangle \cdot u_j(i)}$$

Ligne i de la matrice X_d

Ainsi $X_d^{(i)} \in \text{Vect} \{v_1, \dots, v_d\}$

et $X^{(i)} - X_d^{(i)} \in \text{Vect} \{v_{d+1}, \dots, v_n\}$

Comme la famille $\{v_1, \dots, v_n\}$ est orthogonale, il vient

$$X_d^{(i)} \perp X^{(i)} - X_d^{(i)} \Rightarrow X_d^{(i)} = P_{S_d^*}(X^{(i)})$$

- Les vecteurs propres v_1, \dots, v_d sont appelés les AXES PRINCIPAUX.
- Les vecteurs (propres) u_1, \dots, u_d sont appelés les FACTEURS PRINCIPAUX.
- $\sigma_1, \dots, \sigma_r$ sont appelés les valeurs singulières.
- c_1, \dots, c_r sont les composantes principales.

$$c_j = \sigma_j(x) u_j = X u_j$$

$$(\text{car } X u_j = X \lambda_j^{-1/2} X^T u_j = \sqrt{\lambda_j} u_j)$$

• Part d'INERTIE: $r_d = \frac{\sum_{k=1}^d \lambda_k}{\sum_{k=1}^p \lambda_k}$

• Règle d'ARRET: EBOULIS des Valeurs propres.

• VOIR PAR EXEMPLE Slides GADAT

<http://perso.math.univ-boulouse.fr/gadat/files/2012/12/04/Acp.pdf>
04_Acp.pdf