

# MÉTHODES À NOYAUX POUR L'ANALYSE DE DONNÉES

Mathieu Fauvel

**gipsa-lab**

19 janvier 2007



**gipsa-lab**

## ① Présentation Générale

Les Données

Idée Principale

Un exemple linéairement séparable

Un exemple non-linéairement séparable

## ② Fonctions noyaux

Théorème

Démonstration

Quelques noyaux semi-défini positif

## ③ Analyse non-linéaire en composante principale (kernel PCA)

Analyse en composante principale

Kernel PCA

Application

## ④ Conclusions

Pour - Contre

Autres méthodes

## ① Présentation Générale

Les Données

Idée Principale

Un exemple linéairement séparable

Un exemple non-linéairement séparable

## ② Fonctions noyaux

Théorème

Démonstration

Quelques noyaux semi-défini positif

## ③ Analyse non-linéaire en composante principale (kernel PCA)

Analyse en composante principale

Kernel PCA

Application

## ④ Conclusions

Pour - Contre

Autres méthodes

## Représentation des données :


- $\mathbf{x} \in \mathbb{R}$  ou  $\mathbb{C}$
- $\mathbf{x} \in \mathbb{R}^n$  ou  $\mathbb{C}^n$
- $\mathbf{x} \in \mathbb{R}^n \times \mathbb{R}^n$  ou  $\mathbb{C}^n \times \mathbb{C}^n$
- $\mathbf{x} \in (\Omega, \sigma, P)$
- $\mathbf{x} \in$  ensemble de toutes les séquences finies de l'alphabet  $\{A, C, G, T\}$  ( $\mathbf{x}$  est une séquences d'ADN)
- $\mathbf{x} \subset \mathcal{P}(E)$
- ...

**Notations** :  $\mathcal{X}$  un ensemble quelconque, un objet  $\mathbf{x} \in \mathcal{X}$  et  $\mathcal{S} = \{\mathbf{x}^1, \dots, \mathbf{x}^N\}$  un ensemble fini de  $N$  objets à notre disposition.


**Méthodes à noyaux** : Transformer tout algorithme linéaire, s'exprimant sous forme de produits scalaires, en un algorithme non linéaire.

**Idée de Base** :

- Projeter les données dans un espace vectoriel
- Chercher des relations linéaires dans cet espace



Classification :  $\mathcal{S} = \{(\mathbf{x}^i, y_i) \in \mathbb{R}^n \times \{-1; 1\}; i \in [1, N]\}$



$$\|M_1 - \mathbf{x}\|^2 \stackrel{?}{\geq} \|M_{-1} - \mathbf{x}\|^2$$

$$\|M_1 - \mathbf{x}\|^2 - \|M_{-1} - \mathbf{x}\|^2 \stackrel{?}{\geq} 0$$

$$\begin{aligned}
 \|M_1 - \mathbf{x}\|^2 &= \left\langle \frac{1}{m_1} \sum_{i=1}^{m_1} \mathbf{x}^i - \mathbf{x}, \frac{1}{m_1} \sum_{i=1}^{m_1} \mathbf{x}^i - \mathbf{x} \right\rangle \\
 &= \left\langle \frac{1}{m_1} \sum_{i=1}^{m_1} \mathbf{x}^i, \frac{1}{m_1} \sum_{i=1}^{m_1} \mathbf{x}^i \right\rangle + \langle \mathbf{x}, \mathbf{x} \rangle - 2 \left\langle \frac{1}{m_1} \sum_{i=1}^{m_1} \mathbf{x}^i, \mathbf{x} \right\rangle \\
 &= \frac{1}{m_1^2} \sum_{i=1}^{m_1} \sum_{k=1}^{m_1} \langle \mathbf{x}^i, \mathbf{x}^k \rangle + \langle \mathbf{x}, \mathbf{x} \rangle - 2 \left\langle \frac{1}{m_1} \sum_{i=1}^{m_1} \mathbf{x}^i, \mathbf{x} \right\rangle \\
 \|M_{-1} - \mathbf{x}\|^2 &= \frac{1}{m_{-1}^2} \sum_{j=1}^{m_{-1}} \sum_{l=1}^{m_{-1}} \langle \mathbf{x}^j, \mathbf{x}^l \rangle + \langle \mathbf{x}, \mathbf{x} \rangle - 2 \left\langle \frac{1}{m_{-1}} \sum_{j=1}^{m_{-1}} \mathbf{x}^j, \mathbf{x} \right\rangle
 \end{aligned}$$

Règle de décision :

$$\left\langle -2 \left( \frac{1}{m_1} \sum_{i=1}^{m_1} \mathbf{x}^i - \frac{1}{m_{-1}} \sum_{j=1}^{m_{-1}} \mathbf{x}^j \right), \mathbf{x} \right\rangle + \frac{1}{m_1^2} \sum_{i=1}^{m_1} \sum_{k=1}^{m_1} \langle \mathbf{x}^i, \mathbf{x}^k \rangle - \frac{1}{m_{-1}^2} \sum_{j=1}^{m_{-1}} \sum_{l=1}^{m_{-1}} \langle \mathbf{x}^j, \mathbf{x}^l \rangle \stackrel{?}{\geq} 0$$

Étudier le signe :

$$f(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle + b$$

$$\mathbf{w} = -2 \sum_{m=1}^{m_1+m_{-1}} \alpha_m y_m \mathbf{x}^m$$


$$\alpha_m = \frac{1}{m_1} \text{ ou } \frac{1}{m_{-1}}$$


$$y_m = 1 \text{ ou } -1$$

$$b = \frac{1}{m_1^2} \sum_{i=1}^{m_1} \sum_{k=1}^{m_1} \langle \mathbf{x}^i, \mathbf{x}^k \rangle - \frac{1}{m_{-1}^2} \sum_{j=1}^{m_{-1}} \sum_{l=1}^{m_{-1}} \langle \mathbf{x}^j, \mathbf{x}^l \rangle$$




Séparation :  $\{\mathbf{x} | f(\mathbf{x}) = 0\}$ .






Projection :

$$\begin{aligned}\Phi : \mathbb{R}^2 &\rightarrow \mathbb{R}^3 \\ \mathbf{x} &\mapsto \Phi(\mathbf{x}) \\ (x_1, x_2) &\mapsto (x_1^2, x_2^2, \sqrt{2}x_1x_2)\end{aligned}$$







## Ré-écriture du produit scalaire : $\langle \Phi(\mathbf{x}), \Phi(\mathbf{y}) \rangle_{\mathbb{R}^3}$

$$\begin{aligned}\sum_{i=1}^3 \Phi(\mathbf{x})_i \Phi(\mathbf{y})_i &= \Phi(\mathbf{x})_1 \Phi(\mathbf{y})_1 + \Phi(\mathbf{x})_2 \Phi(\mathbf{y})_2 + \Phi(\mathbf{x})_3 \Phi(\mathbf{y})_3 \\ &= x_1^2 y_1^2 + x_2^2 y_2^2 + 2x_1 x_2 y_1 y_2 \\ &= (x_1 y_1 + x_2 y_2)^2 \\ &= \langle \mathbf{x}, \mathbf{y} \rangle_{\mathbb{R}^2}^2 \\ &= k(\mathbf{x}, \mathbf{y})\end{aligned}$$

## Ré-écriture de la règle de décision :

$$\begin{aligned}f(\mathbf{x}) &= k(\mathbf{w}, \mathbf{x}) + b \\ b &= \frac{1}{m_1^2} \sum_{\substack{i=1 \\ k=1}}^{m_1} k(\mathbf{x}^i, \mathbf{x}^k) - \frac{1}{m_{-1}^2} \sum_{\substack{j=1 \\ l=1}}^{m_{-1}} k(\mathbf{x}^j, \mathbf{x}^l)\end{aligned}$$





Pour quelles fonctions  $k$  a-t on :

$$k(\mathbf{x}, \mathbf{y}) = \langle \Phi(\mathbf{x}), \Phi(\mathbf{y}) \rangle_{\mathcal{H}}$$

## ① Présentation Générale

Les Données

Idée Principale

Un exemple linéairement séparable

Un exemple non-linéairement séparable

## ② Fonctions noyaux

Théorème

Démonstration

Quelques noyaux semi-défini positif

## ③ Analyse non-linéaire en composante principale (kernel PCA)

Analyse en composante principale

Kernel PCA

Application

## ④ Conclusions

Pour - Contre

Autres méthodes



Pour quelles fonctions  $k$  a-t-on l'égalité suivante :

$$k(\mathbf{x}, \mathbf{y}) = \langle \Phi(\mathbf{x}), \Phi(\mathbf{y}) \rangle_{\mathcal{H}}$$

avec

$$k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$$

$$\Phi : \mathcal{X} \rightarrow \mathcal{H}$$

$$(\mathbf{x}, \mathbf{y}) \mapsto k(\mathbf{x}, \mathbf{y})$$

$$\mathbf{x} \mapsto \Phi(\mathbf{x})$$

Theorem (Théorème de Moore-Aronsjan (1950))

*A chaque noyau semi-défini positif  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ , on peut associer un unique espace de Hilbert  $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$  ayant  $k$  comme noyau reproduisant :*

$$\forall f \in \mathcal{H}, \forall \mathbf{x} \in \mathcal{X}, f(\mathbf{x}) = \langle f, k(\cdot, \mathbf{x}) \rangle_{\mathcal{H}}$$

**Noyau semi défini positif** :  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  est semi défini positif si :

- ①  $\forall (\mathbf{x}, \mathbf{y}) \in \mathcal{X} \times \mathcal{X}; k(\mathbf{x}, \mathbf{y}) = k(\mathbf{y}, \mathbf{x})$
- ②  $\forall n \in \mathbb{N}, \forall \xi_1 \dots \xi_n \in \mathbb{R}, \forall \mathbf{x}^1 \dots \mathbf{x}^n \in \mathcal{X}, \sum_{i,j}^n \xi_i \xi_j k(\mathbf{x}^i, \mathbf{x}^j) \geq 0$

**Espace de Banach** : Espace vectoriel normé complet pour la distance issue de sa norme.

**Espace de Hilbert** : Espace de Banach dont la norme  $\|\cdot\|$  découle d'un produit scalaire :  $\|\mathbf{x}\|_{\mathcal{H}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathcal{H}}}$ .

**Espace de Hilbert à noyau auto-reproduisant** : Soit  $\mathcal{X}$  un espace quelconque,  $\mathcal{H}$  un espace vectoriel de fonctions définies sur  $\mathcal{X}$  à valeurs réelles ;  $\mathcal{H} \subset \mathbb{R}^{\mathcal{X}}$  et  $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$  un espace de Hilbert. La fonction  $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  est un noyau reproduisant si :

- ①  $\forall \mathbf{y} \in \mathcal{X} : K(\cdot, \mathbf{y}) : \mathbf{x} \mapsto K(\mathbf{x}, \mathbf{y}) \in \mathcal{H}$
- ②  $\forall \mathbf{y} \in \mathcal{X}$  et  $\forall f \in \mathcal{H} : f(\mathbf{y}) = \langle f, K(\cdot, \mathbf{y}) \rangle_{\mathcal{H}}$

Propriété reproduisante :  $K(\mathbf{x}, \mathbf{y}) = \langle K(\cdot, \mathbf{x}), K(\cdot, \mathbf{y}) \rangle_{\mathcal{H}}$ .

**Noyau semi défini positif** :  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  est semi défini positif si :

- 1  $\forall (\mathbf{x}, \mathbf{y}) \in \mathcal{X} \times \mathcal{X}; k(\mathbf{x}, \mathbf{y}) = k(\mathbf{y}, \mathbf{x})$
- 2  $\forall n \in \mathbb{N}, \forall \xi_1 \dots \xi_n \in \mathbb{R}, \forall \mathbf{x}^1 \dots \mathbf{x}^n \in \mathcal{X}, \sum_{i,j}^n \xi_i \xi_j k(\mathbf{x}^i, \mathbf{x}^j) \geq 0$

**Espace de Banach** : Espace vectoriel normé complet pour la distance issue de sa norme.

**Espace de Hilbert** : Espace de Banach dont la norme  $\|\cdot\|$  découle d'un produit scalaire :  $\|\mathbf{x}\|_{\mathcal{H}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathcal{H}}}$ .

**Espace de Hilbert à noyau auto-reproduisant** : Soit  $\mathcal{X}$  un espace quelconque,  $\mathcal{H}$  un espace vectoriel de fonctions définies sur  $\mathcal{X}$  à valeurs réelles ;  $\mathcal{H} \subset \mathbb{R}^{\mathcal{X}}$  et  $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$  un espace de Hilbert. La fonction  $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  est un noyau reproduisant si :

- 1  $\forall \mathbf{y} \in \mathcal{X} : K(\cdot, \mathbf{y}) : \mathbf{x} \mapsto K(\mathbf{x}, \mathbf{y}) \in \mathcal{H}$
- 2  $\forall \mathbf{y} \in \mathcal{X} \text{ et } \forall f \in \mathcal{H} : f(\mathbf{y}) = \langle f, K(\cdot, \mathbf{y}) \rangle_{\mathcal{H}}$

Propriété reproduisante :  $K(\mathbf{x}, \mathbf{y}) = \langle K(\cdot, \mathbf{x}), K(\cdot, \mathbf{y}) \rangle_{\mathcal{H}}$ .

**Noyau semi défini positif** :  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  est semi défini positif si :

- ①  $\forall (\mathbf{x}, \mathbf{y}) \in \mathcal{X} \times \mathcal{X}; k(\mathbf{x}, \mathbf{y}) = k(\mathbf{y}, \mathbf{x})$
- ②  $\forall n \in \mathbb{N}, \forall \xi_1 \dots \xi_n \in \mathbb{R}, \forall \mathbf{x}^1 \dots \mathbf{x}^n \in \mathcal{X}, \sum_{i,j}^n \xi_i \xi_j k(\mathbf{x}^i, \mathbf{x}^j) \geq 0$

**Espace de Banach** : Espace vectoriel normé complet pour la distance issue de sa norme.

**Espace de Hilbert** : Espace de Banach dont la norme  $\|\cdot\|$  découle d'un produit scalaire :  $\|\mathbf{x}\|_{\mathcal{H}} = \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathcal{H}}}$ .

**Espace de Hilbert à noyau auto-reproduisant** : Soit  $\mathcal{X}$  un espace quelconque,  $\mathcal{H}$  un espace vectoriel de fonctions définies sur  $\mathcal{X}$  à valeurs réelles ;  $\mathcal{H} \subset \mathbb{R}^{\mathcal{X}}$  et  $(\mathcal{H}, \langle \cdot, \cdot \rangle_{\mathcal{H}})$  un espace de Hilbert. La fonction  $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$  est un noyau reproduisant si :

- ①  $\forall \mathbf{y} \in \mathcal{X} : K(\cdot, \mathbf{y}) : \mathbf{x} \mapsto K(\mathbf{x}, \mathbf{y}) \in \mathcal{H}$
- ②  $\forall \mathbf{y} \in \mathcal{X}$  et  $\forall f \in \mathcal{H} : f(\mathbf{y}) = \langle f, K(\cdot, \mathbf{y}) \rangle_{\mathcal{H}}$

Propriété reproduisante :  $K(\mathbf{x}, \mathbf{y}) = \langle K(\cdot, \mathbf{x}), K(\cdot, \mathbf{y}) \rangle_{\mathcal{H}}$ .

## Propriétés des noyaux auto-reproduisant (a.r.) :

- 1 Si  $K$  existe, alors il est unique
- 2 Un noyau a.r. est un noyau semi-défini positif :

### Preuve 2.

- $K(\mathbf{x}, \mathbf{y}) = \langle K(., \mathbf{x}), K(., \mathbf{y}) \rangle_{\mathcal{H}} = \langle K(., \mathbf{y}), K(., \mathbf{x}) \rangle_{\mathcal{H}} = K(\mathbf{y}, \mathbf{x})$
- $$\sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j K(\mathbf{x}^i, \mathbf{x}^j) = \sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j \langle K(., \mathbf{x}^i), K(., \mathbf{x}^j) \rangle_{\mathcal{H}} =$$
$$\left\langle \sum_{i=1}^n \xi_i K(., \mathbf{x}^i), \sum_{j=1}^n \xi_j K(., \mathbf{x}^j) \right\rangle_{\mathcal{H}} = \left\| \sum_{i=1}^n \xi_i K(., \mathbf{x}^i) \right\|_{\mathcal{H}}^2 \geq 0$$



## Construction de l'espace de Hilbert :

$k$  : un noyau semi-défini positif,  $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$

$\mathcal{H}_0$  espace vectoriel des combinaisons linéaires finies :

$$f := \sum_{i=1}^p \alpha_i k(., \mathbf{x}^i) | \mathbf{x}^i \in \mathcal{X}, \alpha_i \in \mathbb{R} \text{ et } p \in \mathbb{N}$$

On définit :

$$\langle f, g \rangle_{\mathcal{H}_0} := \sum_{i,j=1}^{p,q} \alpha_i \beta_j k(\mathbf{x}^i, \mathbf{y}^j)$$

Montrons que  $\langle f, g \rangle_{\mathcal{H}_0}$  est un produit scalaire :

- Indépendant de la base de représentation
- bilinéaire (*immédiat*)
- symétrique (*immédiat*)
- positif
- défini

Indépendance de la représentation de  $f$  et  $g$ .

$$\langle f, g \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i \sum_{j=1}^q \beta_j k(\mathbf{x}^i, \mathbf{y}^j) = \sum_{i=1}^p \alpha_i g(\mathbf{x}^i) = \sum_{j=1}^q \beta_j f(\mathbf{y}^j)$$



Positivité.

$$\langle f, f \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i \alpha_j k(\mathbf{x}^i, \mathbf{x}^j) \geq 0, \forall \alpha_i, \mathbf{x}^i, p. \text{ } k \text{ est un noyau semi-défini}$$

positif.



Défini.

$$\text{Remarquons : } \langle f, k(\cdot, \mathbf{x}) \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i k(\mathbf{x}^i, \mathbf{x}) = f(\mathbf{x}) \text{ (prop. reproduisante).}$$

$$|f(\mathbf{x})| = |\langle f, k(\cdot, \mathbf{x}) \rangle_{\mathcal{H}_0}| \leq \|f\|_{\mathcal{H}_0} k(\mathbf{x}, \mathbf{x})^{1/2} \text{ (bilinearité + positivité + symétrie)}$$

$$\text{Donc } \|f\|_{\mathcal{H}_0} = 0 \Rightarrow (f(\mathbf{x}) = 0, \forall \mathbf{x}) \Rightarrow f = 0$$



Indépendance de la représentation de  $f$  et  $g$ .

$$\langle f, g \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i \sum_{j=1}^q \beta_j k(\mathbf{x}^i, \mathbf{y}^j) = \sum_{i=1}^p \alpha_i g(\mathbf{x}^i) = \sum_{j=1}^q \beta_j f(\mathbf{y}^j)$$



Positivité.

$$\langle f, f \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i \sum_{j=1}^p \alpha_j k(\mathbf{x}^i, \mathbf{x}^j) \geq 0, \forall \alpha_i, \mathbf{x}^i, p. \text{ } k \text{ est un noyau semi-défini}$$

positif.



Défini.

$$\text{Remarquons : } \langle f, k(\cdot, \mathbf{x}) \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i k(\mathbf{x}^i, \mathbf{x}) = f(\mathbf{x}) \text{ (prop. reproduisante).}$$

$$|f(\mathbf{x})| = |\langle f, k(\cdot, \mathbf{x}) \rangle_{\mathcal{H}_0}| \leq \|f\|_{\mathcal{H}_0} k(\mathbf{x}, \mathbf{x})^{1/2} \text{ (bilinéarité + positivité + symétrie)}$$

$$\text{Donc } \|f\|_{\mathcal{H}_0} = 0 \Rightarrow (f(\mathbf{x}) = 0, \forall \mathbf{x}) \Rightarrow f = 0$$





Indépendance de la représentation de  $f$  et  $g$ .

$$\langle f, g \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i \sum_{j=1}^q \beta_j k(\mathbf{x}^i, \mathbf{y}^j) = \sum_{i=1}^p \alpha_i g(\mathbf{x}^i) = \sum_{j=1}^q \beta_j f(\mathbf{y}^j)$$



Positivité.

$$\langle f, f \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i \sum_{j=1}^p \alpha_j k(\mathbf{x}^i, \mathbf{x}^j) \geq 0, \forall \alpha_i, \mathbf{x}^i, p. \text{ } k \text{ est un noyau semi-défini}$$

positif.



Défini.

Remarquons :  $\langle f, k(\cdot, \mathbf{x}) \rangle_{\mathcal{H}_0} = \sum_{i=1}^p \alpha_i k(\mathbf{x}^i, \mathbf{x}) = f(\mathbf{x})$  (*prop. reproduisante*).

$|f(\mathbf{x})| = |\langle f, k(\cdot, \mathbf{x}) \rangle_{\mathcal{H}_0}| \leq \|f\|_{\mathcal{H}_0} k(\mathbf{x}, \mathbf{x})^{1/2}$  (*bilinéarité + positivité + symétrie*)

Donc  $\|f\|_{\mathcal{H}_0} = 0 \Rightarrow (f(\mathbf{x}) = 0, \forall \mathbf{x}) \Rightarrow f = 0$



## Theorem (Complété)

*Si  $(\mathcal{E}_0, \langle, \rangle_{\mathcal{E}_0})$  est un espace métrique, il existe un espace métrique  $(\widetilde{\mathcal{E}}_0, \langle, \rangle_{\widetilde{\mathcal{E}}_0})$  complet dont  $(\mathcal{E}_0, \langle, \rangle_{\mathcal{E}_0})$  est un sous espace dense. Cet espace est unique à isométrie près. On l'appelle le complété de  $(\mathcal{E}_0, \langle, \rangle_{\mathcal{E}_0})$*

*$(\widetilde{\mathcal{H}}_0, \langle, \rangle_{\widetilde{\mathcal{H}}_0})$ , complété de  $(\mathcal{H}_0, \langle, \rangle_{\mathcal{H}_0})$ , est un espace Hilbertien. ■*

Conclusion :

$$k \text{ semi-défini positif} \iff k(\mathbf{x}, \mathbf{y}) = \langle k(\cdot, \mathbf{x}), k(\cdot, \mathbf{y}) \rangle_{\mathcal{H}} = \langle \Phi(\mathbf{x}), \Phi(\mathbf{y}) \rangle_{\mathcal{H}}$$

## Theorem (Complété)

*Si  $(\mathcal{E}_0, \langle, \rangle_{\mathcal{E}_0})$  est un espace métrique, il existe un espace métrique  $(\widetilde{\mathcal{E}}_0, \langle, \rangle_{\widetilde{\mathcal{E}}_0})$  complet dont  $(\mathcal{E}_0, \langle, \rangle_{\mathcal{E}_0})$  est un sous espace dense. Cet espace est unique à isométrie près. On l'appelle le complété de  $(\mathcal{E}_0, \langle, \rangle_{\mathcal{E}_0})$*

$(\widetilde{\mathcal{H}}_0, \langle, \rangle_{\widetilde{\mathcal{H}}_0})$ , complété de  $(\mathcal{H}_0, \langle, \rangle_{\mathcal{H}_0})$ , est un espace *Hilbertien*. ■

## Conclusion :

$$k \text{ semi-défini positif} \iff k(\mathbf{x}, \mathbf{y}) = \langle k(\cdot, \mathbf{x}), k(\cdot, \mathbf{y}) \rangle_{\mathcal{H}} = \langle \Phi(\mathbf{x}), \Phi(\mathbf{y}) \rangle_{\mathcal{H}}$$

$(\mathcal{X}, \langle \cdot, \cdot \rangle_{\mathcal{X}})$  espace de Hilbert  $\Rightarrow k(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle_{\mathcal{X}}$  est semi-défini positif.

- $k(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle_{\mathcal{X}} = \langle \mathbf{y}, \mathbf{x} \rangle_{\mathcal{X}} = k(\mathbf{y}, \mathbf{x})$
- $\sum_{i=1}^n \xi_i \xi_j \langle \mathbf{x}^i, \mathbf{x}^j \rangle_{\mathcal{X}} = \left\langle \sum_{i=1}^n \xi_i \mathbf{x}^i, \sum_{j=1}^n \xi_j \mathbf{x}^j \right\rangle_{\mathcal{X}} = \left\| \sum_{i=1}^n \xi_i \mathbf{x}^i \right\|_{\mathcal{X}}^2 \geq 0$



$g : \mathcal{X} \rightarrow \mathbb{R} \Rightarrow k(\mathbf{x}, \mathbf{y}) = g(\mathbf{x}) \cdot g(\mathbf{y})$  est semi-défini positif.

- $k(\mathbf{x}, \mathbf{y}) = g(\mathbf{x}) \cdot g(\mathbf{y}) = g(\mathbf{y}) \cdot g(\mathbf{x}) = k(\mathbf{y}, \mathbf{x})$
- $\sum_{i=1}^n \xi_i \xi_j g(\mathbf{x}^i) \cdot g(\mathbf{x}^j) = \sum_{i=1}^n \xi_i g(\mathbf{x}^i) \sum_{j=1}^n \xi_j g(\mathbf{x}^j) = \left( \sum_{i=1}^n \xi_i g(\mathbf{x}^i) \right)^2 \geq 0$



$k_1$  et  $k_2$  semi-défini positif  $\Rightarrow k_1 + k_2$  semi-défini positif.

- $k(\mathbf{x}, \mathbf{y}) = k_1(\mathbf{x}, \mathbf{y}) + k_2(\mathbf{x}, \mathbf{y}) = k_1(\mathbf{y}, \mathbf{x}) + k_2(\mathbf{y}, \mathbf{x}) = k(\mathbf{y}, \mathbf{x})$
- $\sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j k(\mathbf{x}^i, \mathbf{x}^j) = \sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j k_1(\mathbf{x}^i, \mathbf{x}^j) + \sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j k_2(\mathbf{x}^i, \mathbf{x}^j) \geq 0$



$k_1$  et  $k_2$  semi-défini positif  $\Rightarrow k_1 \cdot k_2$  semi-défini positif.



$k_1$  semi-défini positif  $\Rightarrow k = \exp(k_1)$  est semi-défini positif.

$$\sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j k(\mathbf{x}^i, \mathbf{x}^j) = \sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j \sum_{r=1}^{+\infty} \frac{k_1^r(\mathbf{x}^i, \mathbf{x}^j)}{r!} = \sum_{r=1}^{+\infty} \frac{1}{r!} \sum_{\substack{i=1 \\ j=1}}^n \xi_i \xi_j k_1^r(\mathbf{x}^i, \mathbf{x}^j) \geq 0$$



$k(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle^p$  noyau polynomial d'ordre  $p$ .

- $k_1(\mathbf{x}, \mathbf{y}) = \langle \mathbf{x}, \mathbf{y} \rangle$  est un noyau
- $k_2(\mathbf{x}, \mathbf{y}) = k_1(\mathbf{x}, \mathbf{y}) \cdot k_1(\mathbf{x}, \mathbf{y})$  est un noyau
- ...



Correspond à l'espace de tous les monômes d'ordre  $p$ .

Variante : espace de tous les monômes jusqu'à l'ordre  $p$ .

$$k(\mathbf{x}, \mathbf{y}) = (\langle \mathbf{x}, \mathbf{y} \rangle + q)^p$$

$k(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x}-\mathbf{y}\|_2^2}{\gamma^2}\right)$  noyau radial.

$$\exp\left(-\frac{\|\mathbf{x}-\mathbf{y}\|_2^2}{\gamma^2}\right) = \exp\left(-\frac{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbb{R}^d}}{\gamma^2}\right) \exp\left(-\frac{\langle \mathbf{y}, \mathbf{y} \rangle_{\mathbb{R}^d}}{\gamma^2}\right) \exp\left(2\frac{\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbb{R}^d}}{\gamma^2}\right)$$

$$k_1(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\langle \mathbf{x}, \mathbf{x} \rangle_{\mathbb{R}^d}}{\gamma^2}\right) \cdot \exp\left(-\frac{\langle \mathbf{y}, \mathbf{y} \rangle_{\mathbb{R}^d}}{\gamma^2}\right) = g(\mathbf{x}) \cdot g(\mathbf{y})$$

$$k_2(\mathbf{x}, \mathbf{y}) = \exp\left(2\frac{\langle \mathbf{x}, \mathbf{y} \rangle_{\mathbb{R}^d}}{\gamma^2}\right) = \exp(k_3(\mathbf{x}, \mathbf{y}))$$



Espace de projection associé de dimension infinie.

Autres noyaux :

- $\mathbf{x}, \mathbf{y} \in \mathbb{R}^+$

$$k(\mathbf{x}, \mathbf{y}) = \min(\mathbf{x}, \mathbf{y})$$

- $\mathbf{x}, \mathbf{y} \in (\Omega, \mathcal{F}, \mathbb{P})$  un espace de probabilité.

$$k(\mathbf{x}, \mathbf{y}) = \mathbb{P}(\mathbf{x}, \mathbf{y}) - \mathbb{P}(\mathbf{x})\mathbb{P}(\mathbf{y})$$

(Mesure de similarité d'événements probabilistes)



## ① Présentation Générale

Les Données

Idée Principale

Un exemple linéairement séparable

Un exemple non-linéairement séparable

## ② Fonctions noyaux

Théorème

Démonstration

Quelques noyaux semi-défini positif

## ③ Analyse non-linéaire en composante principale (kernel PCA)

Analyse en composante principale

Kernel PCA

Application

## ④ Conclusions

Pour - Contre

Autres méthodes

Vecteur aléatoire  $\mathbf{x} \in \mathbb{R}^n$ , N observations  $\mathbf{x}^i$ .

## Algorithme

- 1 Centrer
- 2 Matrice de covariance :

$$\mathbf{C}_{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}^i \mathbf{x}^{iT}$$

- 3 Résoudre :

$$\begin{aligned} \lambda \mathbf{v} &= \mathbf{C}_{\mathbf{x}} \mathbf{v} \\ \|\mathbf{v}\|_{\mathbb{R}^n} &= 1 \end{aligned}$$

- 4 Projection sur  $k^{ieme}$  PC :

$$\mathbf{x}_{pc}^k = \langle \mathbf{v}^k, \mathbf{x} \rangle_{\mathbb{R}^n}$$

Projection :

$$\begin{aligned}\Phi : \mathbb{R}^n &\rightarrow \mathcal{H} \\ \mathbf{x} &\mapsto \Phi(\mathbf{x})\end{aligned}$$

Matrice de covariance dans  $\mathcal{H}$  :

$$\mathbf{C}_{\Phi(\mathbf{x})} = \frac{1}{N} \sum_{i=1}^N \Phi(\mathbf{x}^i) \Phi(\mathbf{x}^i)^T$$

Résoudre :

$$\lambda \mathbf{v}_{\Phi} = \mathbf{C}_{\Phi(\mathbf{x})} \mathbf{v}_{\Phi}$$

Projection :

$$\begin{aligned}\Phi : \mathbb{R}^n &\rightarrow \mathcal{H} \\ \mathbf{x} &\mapsto \Phi(\mathbf{x})\end{aligned}$$

Matrice de covariance dans  $\mathcal{H}$  :

$$\mathbf{C}_{\Phi(\mathbf{x})} = \frac{1}{N} \sum_{i=1}^N \Phi(\mathbf{x}^i) \Phi(\mathbf{x}^i)^T$$

Résoudre :

$$\begin{aligned}\lambda \mathbf{v}_{\Phi} &= \mathbf{C}_{\Phi(\mathbf{x})} \mathbf{v}_{\Phi} \\ &= \frac{1}{N} \sum_{i=1}^N \Phi(\mathbf{x}^i) \Phi(\mathbf{x}^i)^T \mathbf{v}_{\Phi}\end{aligned}$$

Projection :

$$\begin{aligned}\Phi : \mathbb{R}^n &\rightarrow \mathcal{H} \\ \mathbf{x} &\mapsto \Phi(\mathbf{x})\end{aligned}$$

Matrice de covariance dans  $\mathcal{H}$  :

$$\mathbf{C}_{\Phi(\mathbf{x})} = \frac{1}{N} \sum_{i=1}^N \Phi(\mathbf{x}^i) \Phi(\mathbf{x}^i)^T$$

Résoudre :

$$\begin{aligned}\lambda \mathbf{v}_{\Phi} &= \mathbf{C}_{\Phi(\mathbf{x})} \mathbf{v}_{\Phi} \\ &= \frac{1}{N} \sum_{i=1}^N \Phi(\mathbf{x}^i) \Phi(\mathbf{x}^i)^T \mathbf{v}_{\Phi} \\ &= \frac{1}{N} \sum_{i=1}^N \langle \Phi(\mathbf{x}^i), \mathbf{v}_{\Phi} \rangle_{\mathcal{H}} \Phi(\mathbf{x}^i)\end{aligned}$$

$\mathbf{v}_\Phi$  est généré par les  $\Phi(\mathbf{x}^i)$  :

$$\mathbf{v}_\Phi = \sum_{i=1}^N \alpha_i \Phi(\mathbf{x}^i)$$

Ré-écriture :

$$\lambda \mathbf{v}_\Phi = \frac{1}{N} \sum_{i=1}^N \langle \Phi(\mathbf{x}^i), \mathbf{v}_\Phi \rangle_{\mathcal{H}} \Phi(\mathbf{x}^i)$$

$$\lambda \sum_{i=1}^N \alpha_i \Phi(\mathbf{x}^i) = \frac{1}{N} \sum_{i=1}^N \langle \Phi(\mathbf{x}^i), \sum_{j=1}^N \alpha_j \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} \Phi(\mathbf{x}^i)$$

$$\lambda \sum_{i=1}^N \alpha_i \Phi(\mathbf{x}^i) = \frac{1}{N} \sum_{j=1}^N \alpha_j \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} \Phi(\mathbf{x}^i)$$

$$\sum_{m=1}^N \langle \Phi(\mathbf{x}_m), \cdot \rangle_{\mathcal{H}}$$

$$\lambda \sum_{m=1}^N \alpha_i \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^m) \rangle_{\mathcal{H}} = \frac{1}{N} \sum_{\substack{i=1 \\ j=1 \\ m=1}}^N \alpha_j \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^m) \rangle_{\mathcal{H}}$$

$\mathbf{K}$  la matrice  $N \times N$ ,  $\mathbf{K}_{ij} := \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}}$

On obtient :

$$\lambda \mathbf{K} \boldsymbol{\alpha} = \frac{1}{N} \mathbf{K}^2 \boldsymbol{\alpha}$$

Les solutions  $\boldsymbol{\alpha}$  sont trouvées par :

$$\lambda \boldsymbol{\alpha} = \frac{1}{N} \mathbf{K} \boldsymbol{\alpha}$$

Connaître  $\boldsymbol{\alpha} \Rightarrow$  connaître  $\mathbf{v}_{\Phi}$

## Preuve.

- $\alpha = \sum_p a_p \beta^p$ , solution de  
 $\lambda \mathbf{K} \alpha = \frac{1}{N} \mathbf{K}^2 \alpha \iff N \lambda \sum_p a_p \mu_p \beta^p = \sum_p a_p \mu_p^2 \beta^p$   
 $\forall p, N \lambda = \mu_p \text{ ou } a_p = 0 \text{ ou } \mu_p = 0$
- $\alpha = \sum_p a_p \beta^p$ , solution de  $\lambda \alpha = \frac{1}{N} \mathbf{K} \alpha \iff N \lambda \sum_p a_p \beta^p = \sum_p a_p \mu_p \beta^p$   
 $\forall p, N \lambda = \mu_p \text{ ou } a_p = 0$
- $\alpha = \beta^p |_{\mu_p = 0}$ . On a  $\mathbf{K} \alpha = 0 \Rightarrow \forall i : \sum_j \mathbf{K}_{ij} \alpha_j = 0$   
 $\Rightarrow \forall i : \sum_j \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} \alpha_j = 0 \Rightarrow \forall i : \langle \Phi(\mathbf{x}^i), \sum_j \alpha_j \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} = 0$



Le vecteur propre de  $\mathbf{C}_{\Phi(\mathbf{x})}$  associé à  $\beta^p |_{\mu_p = 0}$  n'est pas pertinent.

Projection :

$$\Phi(\mathbf{x})_{kpc}^k = \langle \mathbf{v}_{\Phi}^k, \Phi(\mathbf{x}) \rangle_{\mathcal{H}} = \sum_{i=1}^N \alpha_i^k \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}) \rangle_{\mathcal{H}}$$



## Preuve.

- $\alpha = \sum_p a_p \beta^p$ , solution de  
 $\lambda \mathbf{K} \alpha = \frac{1}{N} \mathbf{K}^2 \alpha \iff N \lambda \sum_p a_p \mu_p \beta^p = \sum_p a_p \mu_p^2 \beta^p$   
 $\forall p, N \lambda = \mu_p$  ou  $a_p = 0$  ou  $\mu_p = 0$
- $\alpha = \sum_p a_p \beta^p$ , solution de  $\lambda \alpha = \frac{1}{N} \mathbf{K} \alpha \iff N \lambda \sum_p a_p \beta^p = \sum_p a_p \mu_p \beta^p$   
 $\forall p, N \lambda = \mu_p$  ou  $a_p = 0$
- $\alpha = \beta^p | \mu_p = 0$ . On a  $\mathbf{K} \alpha = 0 \Rightarrow \forall i : \sum_j \mathbf{K}_{ij} \alpha_j = 0$   
 $\Rightarrow \forall i : \sum_j \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} \alpha_j = 0 \Rightarrow \forall i : \langle \Phi(\mathbf{x}^i), \sum_j \alpha_j \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} = 0$



Le vecteur propre de  $\mathbf{C}_{\Phi(\mathbf{x})}$  associé à  $\beta^p | \mu_p = 0$  n'est pas pertinent.

Projection :

$$\Phi(\mathbf{x})_{kpc}^k = \langle \mathbf{v}_{\Phi}^k, \Phi(\mathbf{x}) \rangle_{\mathcal{H}} = \sum_{i=1}^N \alpha_i^k \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}) \rangle_{\mathcal{H}}$$

## Preuve.

- $\alpha = \sum_p a_p \beta^p$ , solution de  
 $\lambda \mathbf{K} \alpha = \frac{1}{N} \mathbf{K}^2 \alpha \iff N \lambda \sum_p a_p \mu_p \beta^p = \sum_p a_p \mu_p^2 \beta^p$   
 $\forall p, N \lambda = \mu_p$  ou  $a_p = 0$  ou  $\mu_p = 0$
- $\alpha = \sum_p a_p \beta^p$ , solution de  $\lambda \alpha = \frac{1}{N} \mathbf{K} \alpha \iff N \lambda \sum_p a_p \beta^p = \sum_p a_p \mu_p \beta^p$   
 $\forall p, N \lambda = \mu_p$  ou  $a_p = 0$
- $\alpha = \beta^p | \mu_p = 0$ . On a  $\mathbf{K} \alpha = 0 \Rightarrow \forall i : \sum_j \mathbf{K}_{ij} \alpha_j = 0$   
 $\Rightarrow \forall i : \sum_j \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} \alpha_j = 0 \Rightarrow \forall i : \langle \Phi(\mathbf{x}^i), \sum_j \alpha_j \Phi(\mathbf{x}^j) \rangle_{\mathcal{H}} = 0$



Le vecteur propre de  $\mathbf{C}_{\Phi(\mathbf{x})}$  associé à  $\beta^p | \mu_p = 0$  n'est pas pertinent.

Projection :

$$\Phi(\mathbf{x})_{kpc}^k = \langle \mathbf{v}_{\Phi}^k, \Phi(\mathbf{x}) \rangle_{\mathcal{H}} = \sum_{i=1}^N \alpha_i^k \langle \Phi(\mathbf{x}^i), \Phi(\mathbf{x}) \rangle_{\mathcal{H}}$$

**Matrice de Gram** : Matrice de tout les produits scalaires possibles.

$$\mathbf{K} = \begin{pmatrix} \langle \Phi(\mathbf{x}^1), \Phi(\mathbf{x}^1) \rangle_{\mathcal{H}} & \langle \Phi(\mathbf{x}^1), \Phi(\mathbf{x}^2) \rangle_{\mathcal{H}} & \dots & \langle \Phi(\mathbf{x}^1), \Phi(\mathbf{x}^N) \rangle_{\mathcal{H}} \\ \langle \Phi(\mathbf{x}^2), \Phi(\mathbf{x}^1) \rangle_{\mathcal{H}} & \langle \Phi(\mathbf{x}^2), \Phi(\mathbf{x}^2) \rangle_{\mathcal{H}} & \dots & \langle \Phi(\mathbf{x}^2), \Phi(\mathbf{x}^N) \rangle_{\mathcal{H}} \\ \vdots & \vdots & \ddots & \vdots \\ \langle \Phi(\mathbf{x}^N), \Phi(\mathbf{x}^1) \rangle_{\mathcal{H}} & \langle \Phi(\mathbf{x}^N), \Phi(\mathbf{x}^2) \rangle_{\mathcal{H}} & \dots & \langle \Phi(\mathbf{x}^N), \Phi(\mathbf{x}^N) \rangle_{\mathcal{H}} \end{pmatrix}$$

**Matrice noyau (kernel matrix)** :

$$\mathbf{K} = \begin{pmatrix} k(\mathbf{x}^1, \mathbf{x}^1) & k(\mathbf{x}^1, \mathbf{x}^2) & \dots & k(\mathbf{x}^1, \mathbf{x}^N) \\ k(\mathbf{x}^2, \mathbf{x}^1) & k(\mathbf{x}^2, \mathbf{x}^2) & \dots & k(\mathbf{x}^2, \mathbf{x}^N) \\ \vdots & \vdots & \ddots & \vdots \\ k(\mathbf{x}^N, \mathbf{x}^1) & k(\mathbf{x}^N, \mathbf{x}^2) & \dots & k(\mathbf{x}^N, \mathbf{x}^N) \end{pmatrix}$$

## Algorithme


- 1 Construire et centrer  $\mathbf{K}$
- 2 Diagonaliser  $\mathbf{K}$
- 3 Normalisation des vecteurs propres :

$$\lambda_k \langle \boldsymbol{\alpha}^k, \boldsymbol{\alpha}^k \rangle = 1$$


- 4 Projection sur  $k^{ieme}$  KPC :

$$\Phi(\mathbf{x})_{kpc}^k = \sum_{i=1}^N \alpha_i^k k(\mathbf{x}^i, \mathbf{x})$$

## Un autre exemple...



originale



2 premières kpc

## Application aux images hyperspectrales :



pc1



pc2



kpc1



kpc2

## ① Présentation Générale

Les Données

Idée Principale

Un exemple linéairement séparable

Un exemple non-linéairement séparable

## ② Fonctions noyaux

Théorème

Démonstration

Quelques noyaux semi-défini positif

## ③ Analyse non-linéaire en composante principale (kernel PCA)

Analyse en composante principale

Kernel PCA

Application

## ④ Conclusions

Pour - Contre

Autres méthodes

## Avantages :

- Fondement théorique
- Analyse non linéaire
- Utilisation d'*a priori* pour les noyaux
- Implémentation facile

## Inconvénients :

- Stockage Kernel Matrice
- Boîte noire de certain noyaux (RBF)



- Kernel ICA
- Kernel Fisher discriminant analysis
- Support Vector Machines
- Kernel Maximum Likelihood

# MÉTHODES À NOYAUX POUR L'ANALYSE DE DONNÉES

Mathieu Fauvel

**gipsa-lab**

19 janvier 2007